

**Електротрехнички факултет – Универзитет у  
Београду**

**Катедра за сигнале и системе**

## **Неуралне мреже – први пројектни задатак**

Варијанте:

$$A=5$$

$$B=4$$

$$f1=20$$

$$f2=6$$

$$P=1$$

$$Q=5$$


Јана Тољага 2018/0023

Димитрије Панић 2018/0205

## Први задатак


$h(x)=5\sin(40\pi x)+4\sin(12\pi x)$  – функција без шума

$y(x)$  – функција са шумом




За функцију активације смо изабрали – tansig.


Одабрана архитектура мреже:




## Крива перформанси:



## Регресиона крива:




## Предикција неуралне мреже:



Циљ обучавања дате неуралне мреже је био да изолујемо користан сигнал из  $y(x)$  од шума. На слици се може приметити да је предикција неуралне мреже (приказано плавом бојом) успела да издвоји само валидан сигнал.


## Други задатак

На слици је приказана расподела одбирака по класама:




Податке смо поделили тако да нам тренинг скуп садржи 85%, док нам тест скуп садржи 15% улазних података. Поделу смо одрадили да бисмо могли да утврдимо прецизност наше неуралне мреже на подацима које раније није видела (тест скуп). Тако добијамо стварну слику колико је добро истренирана наша неурална мрежа. Тренинг скуп представља податке над којим обучавамо неуралну мрежу. Такође, скупови су бирани на случајан начин како бисмо се осигурали да имамо подједнак број одбирака из свих класа.


Архитектура оптималне неуралне мреже:




Архитектура недовољно комплексне неуралне мреже:




Архитектура превише сложене неуралне мреже:



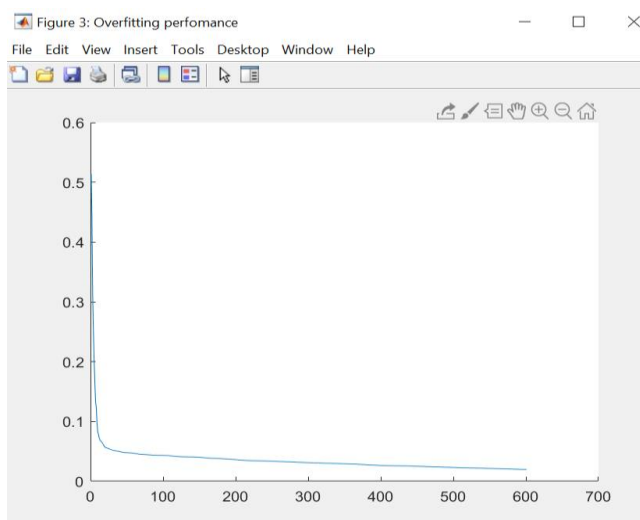
Крива перформанси мреже са оптималном архитектуром:



Крива перформанси мреже са недовољно комплексном архитектуром:

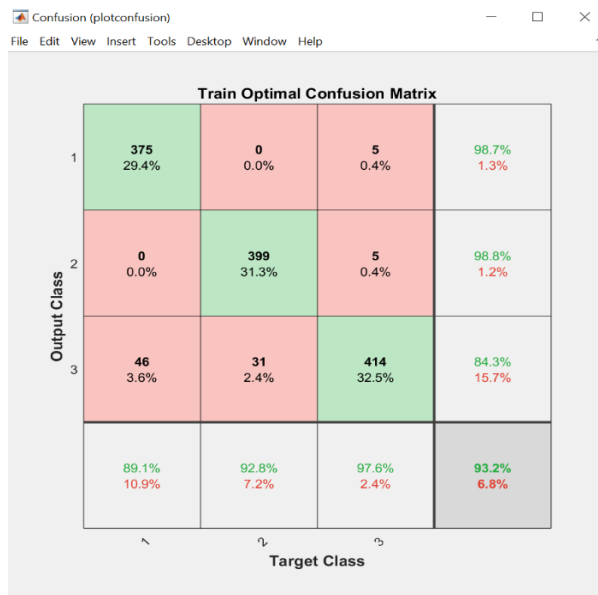


Крива перформанси мреже са превише комплексном архитектуром:

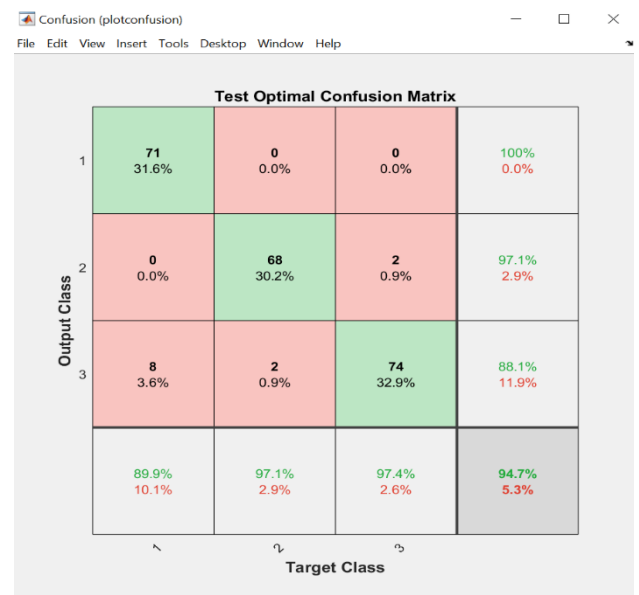


Конфузионна матрица оптималне архитектуре:

Тренинг скуп:

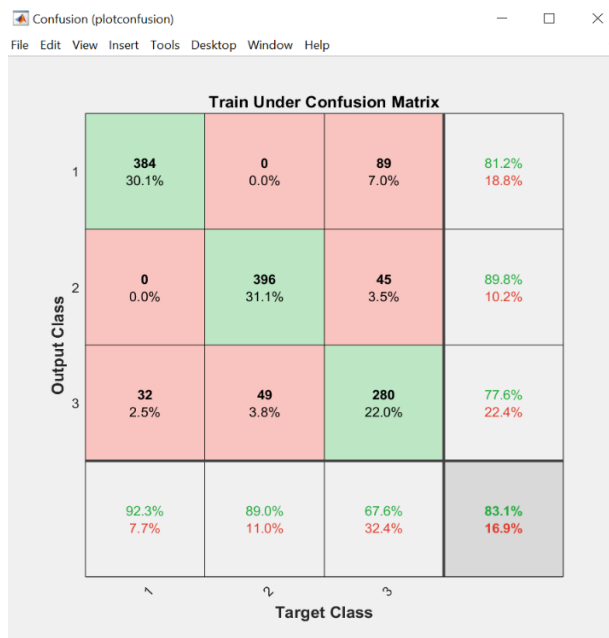


Тест скуп:

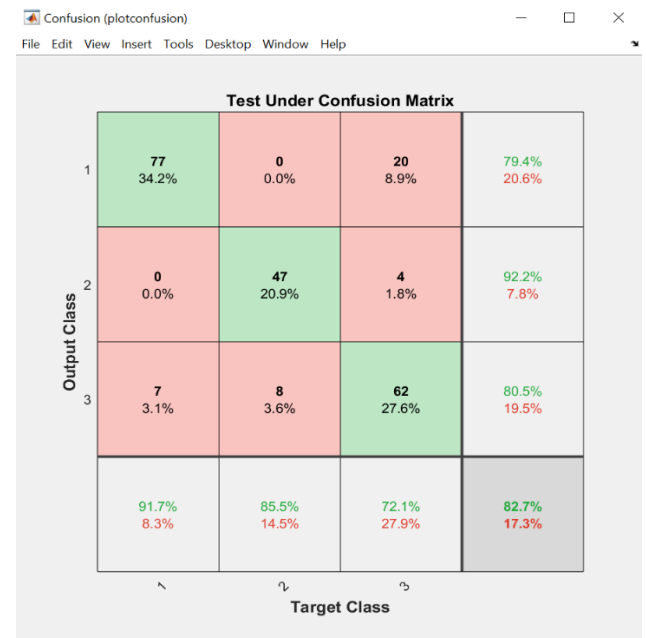


Конфузионна матрица недовољно сложене архитектуре:

Тренинг скуп:



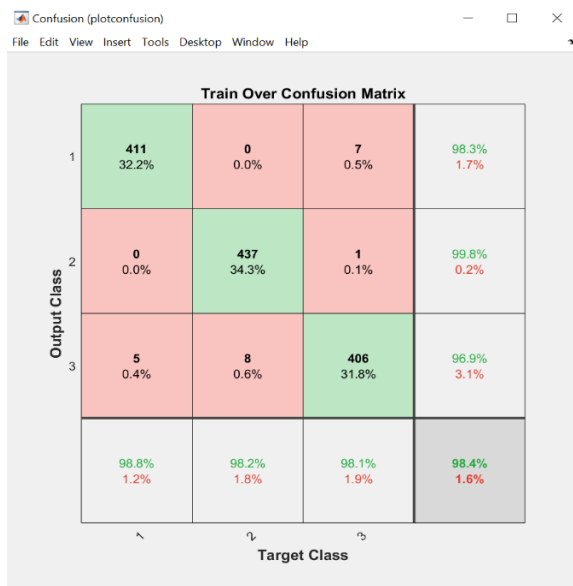
Тест скуп:



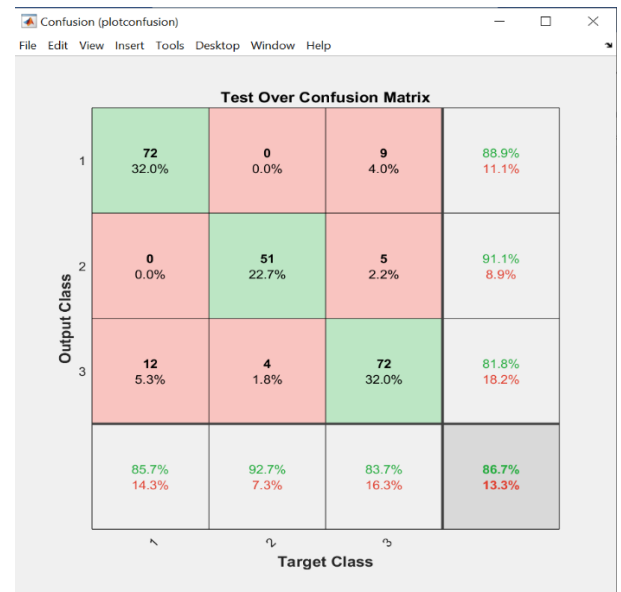


Конфузиона матрица превише сложене архитектуре:

Тренинг скуп:



Тест скуп:



Израчунате Recall и Precision вредности:

$$P = \frac{\text{True positive}}{\text{True positive} + \text{False positive}}$$

$$R = \frac{\text{True positive}}{\text{True positive} + \text{False negative}}$$

Вредности за оптималну архитектуру:

$$P=1$$

$$R=0.8987$$

Вредности за недовољно комплексну архитектуру:

$$P=0.7938$$


$$R=0.9167$$

Вредности за превише комплексну архитектуру:

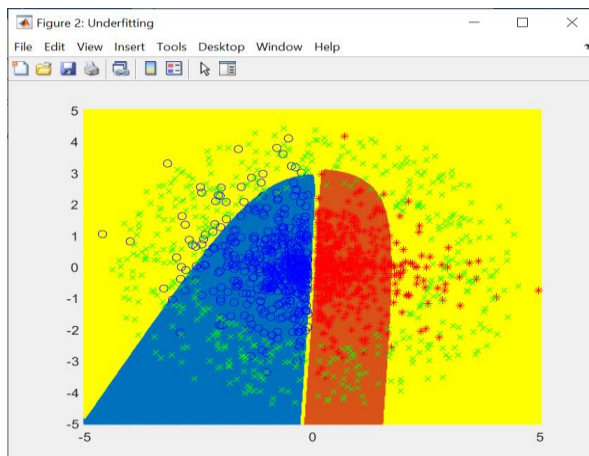
$$P=0.8889$$

$$R=0.8571$$

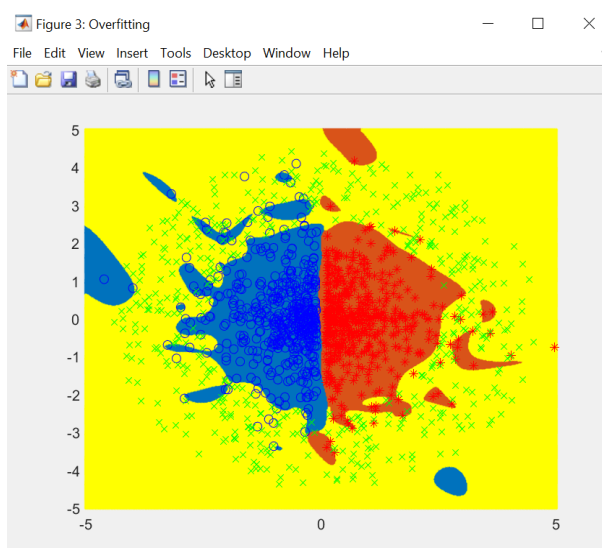
Граница одлучивања за мрежу са оптималном архитектуром:



Граница одлучивања за мрежу са недовољно комплексном архитектуром:



Граница одлучивања за мрежу са превише комплексном архитектуром:



Граница одлучивања нам веродостојно приказује тачност класификације. У случају мреже са оптималном архитектуром можемо да закључимо да није дошло до преобучавања. Мрежа не покушава да класификује сваки примерак своје класе, јер одређен број тих примерака се преклапа са примерцима осталих класа. Фокусира се на област где су подаци њене класе најбројнији. Мрежа је обухватила те области, па закључујемо да је оптимално обучена.

У случају мреже са недовољно комплексном архитектуром можемо да закључимо да се мрежа није довољно обучила јер обухвата и оне области где примерци одговарајућих класа нису заступљени.

Мрежа са превише комплексном архитектуром је покушавајући да успешно класификује сваки примерак одговарајуће класе, обухватила области где су њени подаци ретки. Као последица на графику немамо глатке границе између класа, већ су оне са доста избочина.

## Трећи задатак

Наш скуп података (eng. dataset) садржи податке добијене из гасне турбине, који представљају емисију штетног гаса CO. Подаци су прикупљани у временском периоду од 01.01.2011. до 31.12.2015. у северозападној Турској.

Улазни параметри које смо користили да бисмо предвидели количину штетног гаса CO су:

1. Температура околине (AT)
2. Спољашни притисак (AP)
3. Влажност ваздуха околине (AH)
4. Диференцијални притисак у ваздушном филтеру (AFDP)
5. Излазни притисак турбине (GTEP)
6. Улазна температура турбине (TIT)
7. Излазна температура турбине (TAT)
8. Излазни притисак компресора (CDP)
9. Произведена енергије (TEY)

Ово представља проблем регресије.

Податке смо поделили тако да нам тренинг скуп садржи 85%, док нам тест скуп садржи 15% улазних података. Тренинг скуп смо даље поделили у односу 90:10, где 10% чини валидациони скуп. Тренинг скуп представља податке над којим обучавамо неуралну мрежу, а тест скуп податке над којима проверамо тачност неуралне мреже. Валидациони скуп нам служи приликом раног заустављања, како бисмо детектовали да је дошло до преобучавања. До преобучавања долази када валидациона крива почне да расте, што показује да перформансе над овим скупом опадају иако се перформансе тренинг скупа побољшавају. Такође, скупови су бирани на случајан начин како бисмо се осигурали да имамо подједнак број одбирака из свих класа.

Хиперпараметри који су узети у обзир су:

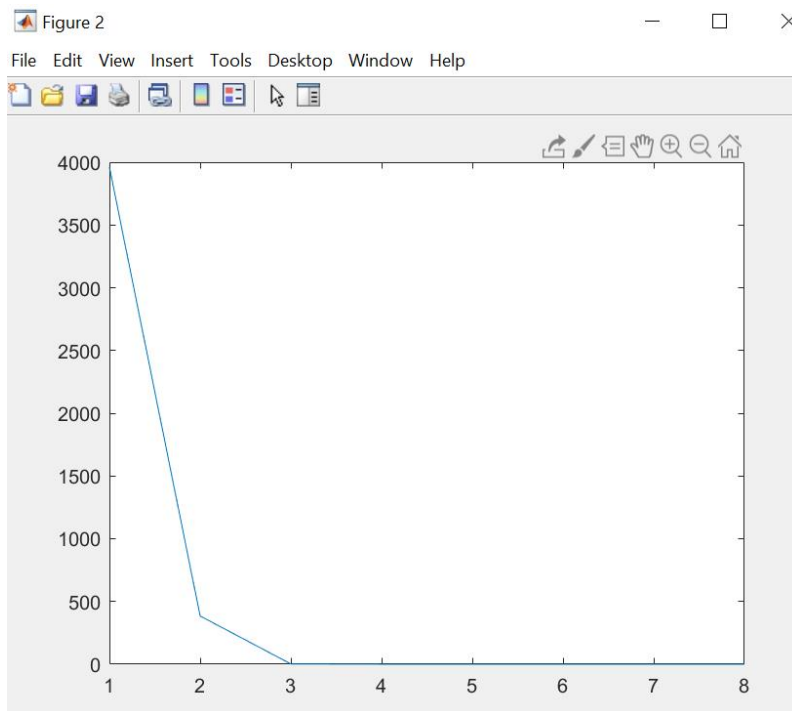
1. Архитектура мреже ([20,25,30,25],[25,30,30],[28,22,18,19],[25,19,35])
2. Функције активације (logsig, poslin, softmax, tansig)
3. Коефицијент регуларизације (0.3, 0.5, 0.75, 0.9)

Произвољно смо бирали параметре, па их подешавали.


Одабране вредности хиперпараметара су:

- Архитектура мреже: [25,19,35]
- Функција активације: poslin
- Коефицијент регуларизације: 0.9


Крива перформансе неуралне мреже у зависности од епохе (број епоха је 14):



Регресиона крива тренинг скупа :



Регресиона крива тест скупа:



Регресиона крива нам показује да се подаци групишу око осе  $y=x$ , где је највећа zasiћеност података. Постојање података који нису концентрисани у области zasiћена утичу на лошију тачност.